


Introdução a *Machine Learning* e Redes Neurais

1

IA: Programas com capacidade de aprender como humano.

ML: Algoritmos com capacidade de aprender sem serem explicitamente programados.

DL: Subárea de ML em que RNAs se adaptam e aprendem com grandes quantidades de dados.



Etapas de construção de um modelo de ML:

- **Coleta de dados;**
- **Processamento de dados**
 - Limpeza de dados;
 - Transformação de dados;
 - Extração de características.
- **Treinamento de modelos**
 - Divisão de dados;
 - Treinamento;
 - Validação;
 - **Aplicação e tomada de decisão.**

2

Situações em que a **identificação** de **regularidades** é aplicada:

- **Modelagem:** identificar regularidades permite a criação de modelos que capturam relações consistentes;
- **Generalização:** modelos que capturam regularidades nos dados de treinamento são capazes de generalizar para novos dados;
- **Redução de ruído:** identificar estruturas repetitivas ajuda a separar os sinais relevantes do ruído nos dados.

Deteção, Previsão e Reconhecimento:

- **Deteção:** determinar se algo está **presente ou ausente** nos dados;
- **Reconhecimento:** **identificar e classificar** o **objeto** ou **padrão detectado**;
- **Previsão:** usar dados históricos para **prever valores** ou **eventos**.

3

Reconhecimento:

capacidade dos sistemas computacionais de **identificar padrões**, objetos ou entidades em dados **com base em exemplos** previamente aprendidos.



Padrão: descrição de um **objeto**, que permite identificar características recorrentes em um conjunto de dados.



Objeto: uma **entidade ou unidade de dados** que possui características específicas que podem ser analisadas para identificar regularidades.



Características: **propriedades ou atributos mensuráveis** que descrevem os objetos e permitem diferenciá-los entre si.



Classes: **Grupos** ou conjuntos **de objetos** que **compartilham** um conjunto comum de **características** ou atributos.

4

Aprendizagem supervisionada:



- Utiliza **objetos e classes conhecidas** para treinar o modelo;
- Objetivo: mapear padrões de entrada para classes corretas e realizar previsões sobre novos dados.

Aprendizagem não supervisionada:



- Modelo trabalha com **dados não rotulados**;
- Objetivo: encontrar padrões ou agrupamentos nos dados sem orientação explícita sobre o que procurar.

Aprendizagem Semi-Supervisionada:

- **Meio-termo** entre a supervisionada e a não supervisionada.

Aprendizagem por reforço:

- O modelo **aprende a tomar decisões** ao interagir com um ambiente.
- Objetivo: maximizar a recompensa total ao longo do tempo



5

Extração de características: a **essência** dos dados deve ser **capturada**, preservando as informações críticas necessárias para as tarefas de análise subsequentes.

Seleção de características: tem como objetivo **identificar** e escolher um **subconjunto das características mais relevantes** para a construção de um modelo de ML.

Normalização do espaço de características: **ajustar as escalas** das características para que todas contribuam igualmente para o modelo. **Transformação** do espaço de características: **destaca padrões ocultos** nos dados, ou torna as características mais apropriadas para o modelo de ML.

Redução da dimensionalidade: **diminui características** do conjunto de dados, mantendo a informação essencial.

6

Espaço de características: espaço multidimensional onde **cada dimensão representa uma característica** dos dados.

Fronteiras de decisão: regiões que separam o espaço de características em **áreas associadas a diferentes classes**.

Principais algoritmos:

- **LDA:** assume que os dados têm distribuição normal por classe e matrizes de covariância iguais;
- **QDA:** variante da LDA, relaxa a suposição de igualdade das matrizes de covariância;
- **RDA:** introduz regularização para lidar com problemas de alta dimensionalidade.

Autovetor: um vetor que, após uma transformação linear, mantém sua direção original.

Autovalor: O escalar pelo qual o autovetor é multiplicado, após a transformação.

Introdução a *Machine Learning* e Redes Neurais

7


Técnicas comuns para codificação de variáveis categóricas:

- **One-Hot Encoding**
- **Label Encoding**

SMOTE: gera exemplos sintéticos para a classe minoritária, interpolando dados existentes em um espaço multidimensional.

RandomUnderSampler: remove aleatoriamente exemplos da classe majoritária para balancear as classes.

Underfitting: ocorre quando um **modelo** é **simples demais** para capturar a complexidade dos dados.



Overfitting: ocorre quando o **modelo se ajusta demais** aos dados de treinamento, memorizando o ruído e perdendo a capacidade de generalizar para novos dados.

8

Coeficiente de determinação: mede a **proporção da variabilidade** da variável dependente explicada pelas variáveis independentes.

Erro Quadrático Médio: ajuda na **avaliação** de **performance** de um modelo de regressão.

Erro Absoluto Médio: mede a **magnitude** média dos erros em um conjunto de previsões.

Raiz do Erro Quadrático Médio: traz a medida de erro para a **mesma escala** da **variável dependente**.

Tipos de regressão:

- **Regressão Linear:** modela a relação linear entre variáveis;
- **Regressão Ridge, Lasso e Elastic Net:** juntas selecionam variáveis e lidam com multicolinearidade;
- **Árvores de Regressão:** capturam relações não-lineares complexas.

RNN possui estrutura cíclica e lida com **dados sequenciais**.

9

KNN: k-Nearest Neighbors: realiza a classificação com base na **vizinhança** de cada amostra de dados

$$\text{Acurácia} = \frac{TP+TN}{TP+TN+FP+FN}$$

$$\text{Precisão} = \frac{TP}{TP+FP}$$

$$\text{Recall} = \frac{TP}{TP+FN}$$

$$F1 = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$

Matriz de confusão: mostra o desempenho do modelo de classificação ao **exibir o número de instâncias verdadeiras e falsas** para cada classe.

Classificadores modernos:

- **XGBoost:** implementa técnicas como regularização para evitar *overfitting* e utiliza otimizações como paralelização e histogramas.
- **LightGBM:** utiliza técnicas como o algoritmo *leaf-wise*.

10

Agrupamento visa **encontrar padrões** em dados não rotulados.



K-Means: divide um conjunto de dados em **K agrupamentos distintos**, onde cada ponto de dados pertence ao agrupamento mais próximo do seu centróide.



DBSCAN: detecta **outliers** e exclui tais dados dos agrupamentos os identificando como ruído, e a definição automática do número de agrupamentos.



Avaliação de agrupamentos: ajuda a **determinar a qualidade** e a **utilidade** dos **clusters** identificados por algoritmos de agrupamento.



11

Neurônio Artificial: abstração simplificada do neurônio biológico



MLP tem três principais estruturas:

- **Camada de Entrada**
- **Camada Escondida**
- **Camada de Saída**

ReLU: substituiu a função sigmoide e ajudou a mitigar o problema do vanishing gradient, pois permite a passagem de sinais positivos e anulando valores negativos, substituindo-os por 0.



A **convolução** oferece uma operação que permite **compreender a vizinhança dos pixels** e reduz a necessidade de tantos pesos.

Transformer: atribui diferentes pesos a diferentes **partes da entrada**, destacando informações mais relevantes.

12

Desde a definição clara e a aplicação prática dos conceitos até a implementação de algoritmos avançados, **cada passo é crucial** para alcançar resultados precisos e úteis.



A maldição da **dimensionalidade** e o **overfitting** (sobreajuste) é vital para criar modelos que não apenas aprendam bem com os dados de treinamento, mas também se generalizem bem para novos dados.



Extração, seleção e normalização de características formam a **base** sobre a qual **modelos robustos** são construídos.